Detección de objetos de interés en videos de cámaras FLIR

Santiago Arenas Rojas, Nicolas Bedoya Figueroa, Juan Guillermo Gutierrez Gamboa, Juan Diego Niebles Navas

Resumen

Esta parte que lo haga gpt al final

Abstract

Esta parte que lo haga gpt al final

Palabras clave:

I. Introducción

A. Contexto del problema

La Fuerza Aeroespacial Colombiana (FAC) está en una búsqueda constante de modernización y tecnificación de sus procesos operativos. Recientemente y de la mano de la Universidad de los Andes, celebran anualmente el evento Codefest Ad Astra con el propósito de incentivar el desarrollo de ideas innovadoras y la generación de productos para la protección del agua, la diversidad y el medio ambiente del país.

Uno de los intereses de la FAC en este sentido es la preservación y cuidado de la Amazonía colombiana. Como parte de esta misión, videos capturados con sensores aerotransportados son analizados con el propósito de examinar y detectar la presencia de campamentos de minería ilegal que pongan en peligro el entorno. Tradicionalmente, este análisis se realiza de forma manual para identificar objetos de interés como carreteras no pavimentadas, dragas y maquinaria en ríos, construcciones, cuerpos de agua, vehículos y carpas.

Es por esto por lo que se busca desarrollar un modelo capaz de procesar las imágenes de los videos, mejorar su calidad, eliminar los elementos de ruido asociado a la captura y finalmente automatizar los procesos de detección de objetos de interés a través de modelos de Deep Learning.

B. Objetivos

Este proyecto busca diseñar e implementar un modelo de procesamiento de video y detección de objetos asociados a minería ilegal mediante deep learning en videos FLIR, estructurando su desarrollo en cuatro etapas clave: (1) preprocesamiento de imágenes térmicas, aplicando filtrado de ruido y ecualización de histograma para mejorar la calidad visual en el 95% de un conjunto de 4,000 imágenes en 5 días; (2) entrenamiento del modelo YOLOv8x con los datos preparados, alcanzando un mAP mínimo del 80% en validación en 7 días; y (3) evaluación y ajuste del modelo con datos FLIR, optimizando hiper parámetros para lograr un F1-score superior a 0.75 en 6 días.

II. Estado del arte

En el campo de la visión por computador, la detección de objetos ha avanzado

considerablemente. Esto se debe a que ha sido impulsada por el desarrollo de arquitecturas de aprendizaje profundo como lo pueden ser las redes neuronales convolucionales (CNN), que han facilitado el aprendizaje de características. Estos avances han sido fundamentales para el procesamiento eficiente de diversos tipos de imágenes, cómo lo pueden ser las térmicas e incluso los videos capturados por vehículos aéreos no tripulados (UAV). A continuación, se van a ver los principales aspectos encontrados en la literatura sobre el análisis de este tipo de imágenes y la arquitectura más común en la actualidad.

A. Detección en Imágenes Térmicas de UAV

Inicialmente, en [1], es posible evidenciar que la detección de objetos en imágenes térmicas desde UAV representa un desafío debido a la baja resolución espacial, la presencia de ruido y la variabilidad en las condiciones ambientales. Para abordar estas limitaciones, se han propuesto métodos basados en modelos como YOLO (You Only Look Once), ya que este cuenta con una arquitectura potente capaz de extraer las características relevantes a pesar de las limitaciones visuales de las cámaras infrarrojas .

El trabajo de [1] también nos propone un marco de detección para imágenes térmicas adquiridas por UAV, utilizando variantes de YOLO (v3, v4, v5) sobre un dataset FLIR. El estudio muestra que YOLOv5-s logra una precisión promedio (mAP) del 88.69% en la detección de personas y vehículos, alcanzando velocidades de hasta 50 FPS, lo que lo convierte en una opción viable para aplicaciones en tiempo real o que requieran una gran precisión.

B. Arquitectura del Modelo YOLO

Ahora que ya se ha mencionado el modelo YOLO, es importante entender el funcionamiento de este, a lo cual [5] nos indica que su gran diferenciador es tratar la detección de objetos como un único problema de regresión, lo que es útil pues permite predecir directamente las coordenadas de las cajas delimitadoras y las probabilidades de clase desde la imagen completa en una sola pasada por la red neuronal. Esto es diferente a los enfoques tradicionales que utilizan etapas separadas para la propuesta de regiones y la clasificación (como R-CNN), ya que YOLO emplea una única red convolucional optimizada de extremo a extremo para maximizar el rendimiento en tareas de detección.

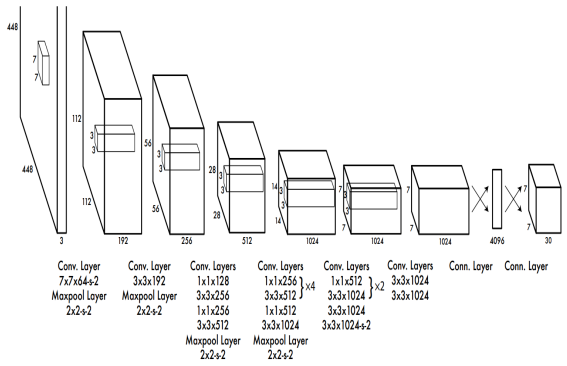

Fig. 1 Imágen representativa del modelo convolucional yolo dada por [5].

Esta red convolucional funciona de la siguiente manera: YOLO utiliza 24 capas convolucionales seguidas por dos capas completamente conectadas. Las capas convolucionales extraen características visuales de la imagen, mientras que las capas finales realizan las predicciones. Este es un modelo relativamente simple por lo que permite velocidades de procesamiento superiores a 45 FPS en GPU modernas, manteniendo una precisión competitiva frente a modelos más complejos [5]. Además, [5] vuelve a confirmar que esta arquitectura permite que YOLO sea altamente eficiente y adecuado para tareas en tiempo real, y, que a pesar de que presenta limitaciones en la detección de objetos

pequeños o muy cercanos entre sí, ha demostrado ser útil en ambientes desafiantes.

B. YOLO y Optimización en Ambientes Desafiantes

En cuanto a los ambientes desafiantes, el uso de YOLOv5 ha demostrado ser eficaz en entornos complejos como los abordados por Mantau et al. [3], donde se entrenó un modelo de detección de humanos utilizando imágenes térmicas y visibles (RGBT) para patrullaje automatizado en áreas forestales. La técnica combinó aprendizaje por transferencia y optimización de parámetros (IoU y confianza), demostrando robustez ante variaciones de iluminación y movimiento desde la perspectiva aérea.

Asimismo, Kowalski et al. [4] compararon YOLOv2, YOLOv3 y Faster R-CNN para detectar embarcaciones inflables y personas en ríos fronterizos. Aunque Faster R-CNN con ResNet101 presentó el mejor rendimiento en términos de precisión, su mayor tiempo de procesamiento favoreció a los modelos YOLO en aplicaciones que requieren detección rápida, particularmente en condiciones climáticas adversas. Esto es útil para este contexto pues indica que puede ser de gran utilidad para el uso de imágenes FLIR, que por naturaleza están contaminadas de ruido.

C. Comparación de Modelos YOLO y Aplicación con Ultralytics

El estudio de Baldovino et al. [9] evaluó distintas versiones del modelo YOLO soportadas por Ultralytics (v3u, 5mu, 6m y 8), orientadas a la detección de objetos grandes en oficinas. Aunque el dominio de análisis era diferente al térmico, los resultados mostraron que los modelos YOLOv5mu y YOLOv8s cuyos valores de mAP superaron el 90% en la mayoría de las clases detectadas demostrando una gran capacidad de generalización en contextos estructurados.

Esta evaluación resalta la eficiencia y estabilidad de las implementaciones de Ultralytics. Su plataforma no solo ofrece soporte activo para múltiples versiones de YOLO, sino que también proporciona herramientas integradas para anotación, entrenamiento y despliegue de modelos, simplificando significativamente el desarrollo de sistemas de detección en condiciones operativas complejas.

E. Limitaciones y Retos Abiertos

Pese a estos avances, subsisten retos importantes. La detección de objetos parcialmente ocultos, la escasa disponibilidad de datasets térmicos anotados y la dificultad para generalizar en condiciones extremas siguen siendo obstáculos técnicos. Adicionalmente, la precisión de los modelos se ve comprometida cuando los objetos son pequeños o están alejados del sensor, un problema común en aplicaciones con UAVs [1], [3].

III. Materiales y Métodos

A. Materiales

Para poder realizar el análisis de las imágenes se utilizó el lenguaje de programación Python en su versión 3.10. Gracias a este se pudo hacer uso de diversas librerías donde las más relevantes son: ultralytics, para poder implementar el modelo YOLOv8; Numpy y Pillow, para la representación y visualización de los resultados y Streamlit, para realizar un despliegue interactivo del modelo.

En cuanto al conjunto de entrada para entrenar el modelo, este fue el dataset de 4000 imágenes FLIR que fueron capturadas y etiquetadas en una operación en la amazonía. Estas imágenes

presentan una baja resolución, representando un desafío para el entrenamiento del modelo.

B. Métodos

La metodología del proyecto se basó en un flujo de cinco etapas. En la primera etapa se realizó un preprocesamiento de las imágenes. Aquí fue necesario utilizar técnicas para reducir el ruido (como la aplicación de un filtro gaussiano y mediano). Luego, se utilizó la librería Ultralytics para hacer uso del modelo YOLOv8m y YOLOv11n, el cual fue entrenado utilizando el dataset FLIR. Posteriormente se realizaron pruebas y visualizaciones con Numpy y Pillow con el fin de poder analizar los resultados del entrenamiento. Después, se utilizó la librería de Streamlit para un despliegue web del modelo y que fuera de fácil acceso para el uso final. Finalmente, se intentó mejorar el modelo mediante el ajuste de los hiper parámetros y repitiendo el preprocesamiento probando con nuevas implementaciones de los filtros mencionados y aumentando el tamaño de los datasets (utilizando específicamente data augmentation) ya que, por defecto, el dataset viene desbalanceados.

IV. Resultados

V. Discusión

***** Aquí se puede hablar del problema con la limpieza de los datos y cómo eso afectó al modelo

VI. Conclusión

Esta parte que lo haga gpt al final

VII. Bibliografía

[1] C. Jiang et al., “Object detection from UAV thermal infrared images and videos using YOLO models,” Int. J. Appl. Earth Obs. Geoinf., vol. 112, 2022.
[2] R. G. Baldovino et al., “Comprehensive analysis on Ultralytics-supported YOLO models for detection and recognition of large office objects for indoor navigation,” Procedia Comput. Sci., vol. 246, pp. 3851–3858, 2024.
[3] A. J. Mantau et al., “A Human-Detection Method Based on YOLOv5 and Transfer Learning Using Thermal Image Data from UAV Perspective for Surveillance System,” Drones, vol. 6, no. 10, 2022.
[4] M. Ł. Kowalski et al., “Detection of Inflatable Boats and People in Thermal Infrared with Deep Learning Methods,” Sensors, vol. 21, no. 5330, 2021.
[5] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You Only Look Once: Unified, Real-Time Object Detection," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), 2016, pp. 779–788.